



Rekonstrukcja i generacja sygnału EEG

Marek Fiuk

Grupa IV

266595@pwr.edu.pl

Szymon Stano

Grupa IV

268777@pwr.edu.pl

Streszczenie

W niniejszej pracy przeanalizowano możliwości zastosowania modelu dyfuzyjnego (DIFF-e) (1) oraz wariacyjnego autoenkodera (VAEEG) (2) w zadaniach rekonstrukcji i generowania sygnałów EEG. Dokonano oceny jakości rekonstruowanych danych w porównaniu do oryginalnych danych. Uzyskane wyniki wskazują na potencjał zastosowanych metod, a opracowane architektury oraz wyuczone reprezentacje ukryte stanowią istotny element dalszych badań w zakresie klasyfikacji sygnałów EEG na danych etykietowanych, w ramach podejścia uczenia transferowego.

1 Wstęp

Elektroencefalografia (EEG) to metoda rejestrowania aktywności mózgu za pomocą elektrod umieszczonych na skórze głowy(3; 2). Jako kluczowy wskaźnik w badaniach elektrofizjologicznych, EEG znajduje szerokie zastosowanie w wielu zaburzeniach neurologicznych, przykładowo takich jak wykrywanie napadów padaczkowych.(4; 2; 5) Ze względu na swoją wysoką rozdzielczość czasową, nieinwazyjność i relatywnie niski koszt, EEG pozostaje jedną z najczęściej stosowanych metod monitorowania aktywności mózgu w zastosowaniach klinicznych i badawczych. Jednocześnie, dane EEG charakteryzują się dużym poziomem szumu, wysoką zmiennością między osobami oraz złożoną strukturą czasowo-częstotliwościową, co czyni ich analizę wyzwaniem wymagającym zaawansowanych metod przetwarzania i reprezentacji.

Niniejsza praca posłużyć może jako wstęp do dalszych badań w obrębie automatycznej klasyfikacji chorób bądź nieprawidłowości w aktywności mózgu przy użyciu sygnału EEG. Przedstawiane przez nas metody rekonstrukcji dostarczają nie tylko możliwość generowania nowych, sztucznych sygnałów EEG, lecz przede wszystkim pozwalają otrzymać ukryte reprezentacje danych zapisów, które stanowią istotny element w dalszych zadaniach klasyfikacji bądź detekcji.

Do przeprowadzenia naszych badań użyliśmy zbioru danych *A Polish Electroencephalography, Alzheimer's Risk-genes, Lifestyle and Neuroimaging (PEARL-Neuro) Database* (6) zawierającego zapisy osób z grupy ryzyka na chorobę Alzheimera. Skupiliśmy się na danych EEG dla zadania Sternberg, badającego pamięć krótkotrwałą pacjentów, które posłużyły za dane wejściowe modeli autoenkodera wariacyjnego oraz modelu dyfuzyjnego dostosowanego do danych temporalnych EEG. Oparliśmy się o istniejące artykuły i implementacje danych architektur (1; 2). W wyniku prac opracowaliśmy dwa modele, które mogą służyć zarówno do generowania syntetycznych danych EEG, jak i stanowić punkt wyjścia do dalszych zadań typu *downstream*, takich jak klasyfikacja stanu poznawczego pacjenta.

2 Powiązane prace

Naszą pracę oparliśmy o dwa artykuły, poruszające tematykę rekonstrukcji sygnału EEG i jej późniejszego zastosowania: *VAEEG: Variational auto-encoder for extracting EEG representation* (2) oraz *Diff-E: Diffusion-based Learning for Decoding Imagined Speech EEG*(1).

W przypadku modelu VAEEG autorzy zaproponowali dedykowaną, uwzględniającą cechy zjawiska, architekturę autoenkodera wariacyjnego, składającego się z sieci konwolucyjnych, połączeń skrótowych, jak i również warstwy LSTM. Sieć ta została wyuczona na dużym, nieoznakowanym zbiorze danych EEG. Model ten następnie został zewaluowany pod względem jakości rekonstrukcji rozważanych sygnałów. Ponadto, wyuczony w ten sposób koder oraz generowane przez niego reprezentacje posłużyły następnie jako cechy wejściowe do klasyfikatorów trenowanych na mniejszych, oznakowanych zbiorach, dotyczących analizy wieku, detekcji napadu padaczkowego oraz klasyfikacji fazy snu.

Drugi artykuł wprowadza model Diff-E który składa się z modułu denoising diffusion probabilistic model (DDPM), autoenkodera z rezydualnymi wejściami z warstw ukrytych modułu ddpm oraz klasyfikatora, który otrzymuje wyjścia z kodera modułu autokodera. Model trenowany jest w sposób semi-supervised poprzez łączenie funkcji straty klasyfikatora, autokodera i modelu dyfuzyjnego w jednym kroku treningowym (1). Autorzy trenują w ten sposób model na danych zadania wyobrażenia mowy i porównują z DeepConvNet (7), EEGNet (8) osiągając znacznie wyższe wyniki. Nie porównują jednak zdolności generacyjnych modelu dyfuzyjnego ani jakości reprezentacji, na których oparliśmy ten artykuł.

Innym podejściem do generowania syntetycznych danych są generatywne sieci kontradiktoryjne (ang. Generative Adversarial Networks, GAN). W obszarze EEG podjęto już prace w tym kierunku (9), co stanowi potencjalny obszar rozwoju naszych eksperymentów.

3 Zbiór danych

Do nauki i ewaluacji rozważanych modeli wykorzystaliśmy dane pochodzące ze zbioru *A Polish Electroencephalography, Alzheimer's Risk-genes, Lifestyle and Neuroimaging (PEARL-Neuro) Database* (6). Jest to zbiór wielomodalny, który integruje informacje z zakresu neuroobrazowania (fMRI), elektroencefalografii (EEG), danych genetycznych (ze szczególnym uwzględnieniem genów związanych z ryzykiem choroby Alzheimera, takich jak APOE), a także obszernych danych behawioralnych i informacji dotyczących stylu życia uczestników. Został on stworzony w celu umożliwienia badań nad wczesnymi markerami ryzyka choroby Alzheimera u osób w średnim wieku, jeszcze przed pojawieniem się objawów klinicznych - nie posiada on więc bezpośrednich etykiet diagnozy choroby. W ramach naszej pracy skoncentrowaliśmy się na podzbiorze danych EEG z tzw. zadania Sternberga, które zostało zaprojektowane w celu oceny pamięci roboczej uczestników. Dane EEG zarejestrowano dla 78 osób w wieku od 50 do 63 lat, a średnia długość zapisów wynosiła ok. 11 minut. Na potrzeby eksperymentów dane podzieliliśmy na:

- zbiór treningowy: 62 osoby,
- zbiór walidacyjny: 7 osób,
- zbiór testowy: 9 osób.

Przykładowa próbka ze zbioru treningowego przedstawiona została na Rysunku 1:

3.1 Wstępne przetwarzanie sygnału

Przed uczeniem modeli dane zostały poddane wstępnemu przetwarzaniu z wykorzystaniem biblioteki MNE-Python (10), która zapewnia zaawansowane narzędzia do analizy sygnałów EEG. Poszczególne kroki preprocessingowe zostały dobrane na podstawie praktyk w rozważanej przez nas literaturze naukowej dotyczącej analizy EEG, z uwzględnieniem specyfiki sygnałów oraz zadania rekonstrukcji. W szczególności wykonano następujące operacje:

1. **Wybór kanałów:** z 128 elektrod wybraliśmy 16 kanałów EEG (Fp1, Fp2, F3, F4, O1, O2, T7, T8, P3, P4, C1, C2, F10, F9, P9, P10), kierując się próbą zapewnienia równomiernego pokrycia całej powierzchni głowy.




Figure 1: Przykładowy sygnał EEG

2. Filtracja:

- filtr pasmowo-przepustowy 30–50 Hz (filtr FIR, okno firwin) - ograniczenie analizy do zakresu wysokich częstotliwości - fali gamma.
- filtr zaporowy (notch) przy 50 Hz i 100 Hz - eliminacja zakłóceń sieciowych.

3. **Resampling:** Obniżenie częstotliwości próbkowania z 1000 Hz do 256 Hz co pozwoliło zmniejszyć rozmiar danych przy zachowaniu kluczowych informacji sygnałowych..

4. **Referencja:** Wspólne odjęcie średniej (common average reference), celem zmniejszenia wpływu artefaktów globalnych.

5. **Standaryzacja:** Każdy kanał EEG został dla każdej osoby przeskalowany do postaci:

$$x_{\text{norm}} = \frac{x - \mu_{\text{chan}}}{\sigma_{\text{chan}}},$$

gdzie μ_{chan} to średnia, a σ_{chan} to odchylenie standardowe kanału.

3.2 Podział na próbki

Każdy z sygnałów EEG podzieliliśmy na niepokrywające się próbki o długości 1 s (256 punktów czasowych). W rezultacie ich całkowita liczba w poszczególnych zbiorach wyniosła:

$$N_{\text{train}} = 49313 \quad N_{\text{val}} = 5531 \quad N_{\text{test}} = 7247.$$

Tak podzielone fragmenty służyły jako wejścia do obydwu modeli. Ze względu na charakterystykę zaproponowanych architektur, VAEED obsługiwał kanały pojedynczo, natomiast DDPM był trenowany na wszystkich kanałach równocześnie. Przykład przetworzonej, pojedynczej próbki znajduje się na Rysunku 2




Figure 2: Próbką przetworzonego sygnału EEG

4 Metody

4.1 Model DDPM - Diff-E

Model *denoising diffusion probabilistic model* opierają swoje działanie na stopniowym zaszumianiu danych szumem gaussowskim w procesie Markowa. W przeciwieństwie do artykułu wprowadzającego zastosowanie modeli dyfuzyjnych do próbkowania obrazów (11), który sugerował przewidywanie szumu gaussowskiego, zastosowaliśmy, możliwie że błędnie cel uczenia na przewidzenie

odszumionej oryginalnej próbki. Jest to jednak zgodne z artykułem o który opieraliśmy nasze badania(1).

$$\mathcal{L}_{\ell_1}(\theta) = x_0 - \hat{x}_\theta(x_t, t)_1 = \sum_{i=1}^d x_0^{(i)} - \hat{x}_\theta(x_t, t)^{(i)} \quad (1)$$

Taka funkcja straty liczy sumę po bezwzględnej różnicy pomiędzy próbką oryginalną, a odszumioną.

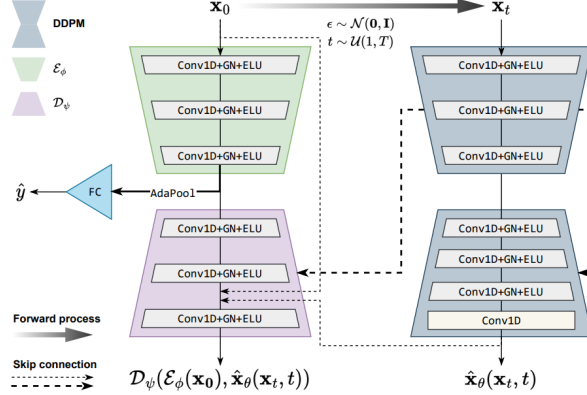


Figure 3: DDPM wyekstrahowany z Diff-E

4.2 Model VAE - VAEEG

Autoenkodery (AE) to modele uczące się reprezentacji danych poprzez stopniowe redukowanie wymiarowości ukrytej warstwy oraz rekonstrukcję oryginalnego sygnału z tej skompresowanej reprezentacji. Proces uczenia polega na minimalizacji różnicy między wejściem a jego rekonstrukcją. Autoenkodery wariacyjne (VAE) rozszerzają tę koncepcję, ucząc się nie pojedynczych punktów w przestrzeni latentnej, lecz parametrów rozkładu prawdopodobieństwa. W warstwie ukrytej próbkujemy się zazwyczaj z rozkładu normalnego, stosując trik reparametryzacji, co umożliwia propagację gradientów. Funkcja straty VAE składa się z dwóch składników: straty rekonstrukcji oraz dywergencji Kullbacka-Leiblera między rozkładem latentnym a wybranym priorem, zwykle rozkładem normalnym.

Architektura VAEEG została zaprojektowana specjalnie do ekstrakcji reprezentacji sygnałów EEG, uwzględniając ich unikalne właściwości, takie jak wysoka wymiarowość, złożona struktura czasowo-przestrzenna oraz obecność szumów. Model VAEEG wykorzystuje głównie warstwy konwolucyjne w enkoderze i dekoderze, które efektywnie wychwytują lokalne wzorce przestrzenne i czasowe w danych EEG. W oryginalnej pracy autorzy dzielą dany sygnał EEG na pięć pasm częstotliwości, które przetwarzane są przez oddzielne enkodery, a reprezentacja ukryta jest złączeniem pojedynczych reprezentacji. W procesie rekonstrukcji ponownie używamy rozłącznych dekoderów, a finalny sygnał jest złożeniem otrzymanych pasm częstotliwości. W naszej pracy ograniczyliśmy się do jednego pasma - gamma - celem ujednolicenia z pracą dotyczącą Diff-E. Działanie modelu przedstawione zostało na Rysunku 4.

5 Eksperymenty i wyniki

Dla modeli zastosowany był algorytm optymalizacyjny RMSProp, który obecny był w obydwu modelach z oryginalnych publikacji. Za rozmiar batcha przyjęliśmy wartość 32.

5.1 VAEEG

Podstawowymi hiperparametrami dla modelu VAEEG były:

- współczynnik uczenia

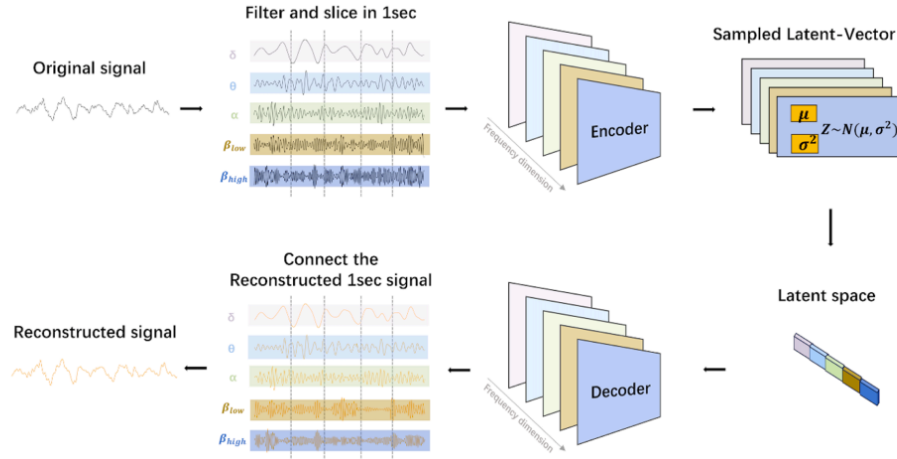


Figure 4: Proces nauki modelu VAE EEG - źródło (2)

- β - współczynnik proporcjonalności pomiędzy dywergencją KL a błędem rekonstrukcji
- rozmiar wektora przestrzeni ukrytej

Pierwsze dwa z nich wybrane zostały dobrane na podstawie empirycznych wyników algorytmu Grid-Search. Ponadto, początkowe wartości β uwzględniały proporcję wartości elementów funkcji straty. Finalnie, najlepsze wyniki uzyskały hiperparametry $lr = 10^{-3}$ oraz $\beta = 10^{-3}$. Rozmiar wektora przestrzeni ukrytej został poddany dalszemu porównaniu.

5.2 Model dyfuzyjny

Trening modelu posiada wiele parametrów w tym współczynnik uczenia, sposoby schedulowania wartości szumu czy wielkość poszczególnych warstw. W eksperymentach użyliśmy takich samych wartości co autorzy pracy wprowadzającej Diff-E(1), poza wielkością warstwy ukrytej. Ten parametr wpływa też na wielkość poszczególnych warstw kodera i dekodera. Porównaliśmy modele o wielkości tego parametru - 64, 128, 198. Według metryk jakości rekonstrukcji model z wielkością ukrytej reprezentacji 128 osiąga najlepsze wyniki, jednak możliwe, że wynika to z dostrojenia pozostałych hiperparametrów do tego rozmiaru, gdyż to także jest identyczna wartość jaka była zastosowana w oryginalnym artykule(1)

5.3 Porównanie

Ze względu na brak etykiet referencyjnych, a co za tym idzie, braku możliwości użycia klasycznych metryk klasyfikacyjnych, skupiliśmy się na ocenie jakości rekonstruowanych sygnałów. Przeprowadziliśmy ją dla kanału Fp1. Podstawowymi, przyjętymi przez nas metrykami były: Normalized Root Mean Square Error (NRMSE), który pozwala na porównywanie błędów rekonstrukcji niezależnie od skali sygnału (Równanie 2).

$$NRMSE = \frac{\sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2}}{\max(x) - \min(x)}. \quad (2)$$

Dodatkowo rozważaliśmy współczynnik korelacji Pearsona, średni błąd bezwzględny (MAE) oraz Peak Signal-to-Noise Ratio (PSNR) który opisuje stosunek maksymalnej możliwej wartości sygnału do poziomu szumu zakłócającego jego reprezentację — w naszym przypadku szumem tym jest błąd rekonstrukcji. Wyższy PSNR oznacza lepszą jakość odtworzonego sygnału (Równanie 3).

$$PSNR = 10 \cdot \log_{10} \left(\frac{(MAX_x)^2}{MSE} \right), \quad (3)$$

gdzie:

- MAX_x — maksymalna możliwa wartość sygnału,
- $MSE = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2$ — błąd średniokwadratowy.

Wyniki metryk porównaliśmy dla różnych modeli: VAEEG z rozmiarami przestrzeni ukrytej kolejno 15,32,64,128 oraz Diff-E kolejno z 64,128,192. Najlepsze wyniki dla obydwu uzyskały kolejno rozmiary 64 i 128, a ich porównanie na zbiorze testowym przedstawione zostało w Tabeli 1 :

Table 1: Porównanie jakości rekonstrukcji sygnału EEG dla modeli VAEEG i Diff-E

Metryka	VAEEG 64	Diff-E 128
NRMSE	0.0816 ± 0.0114	0.1264 ± 0.0728
Pearson	0.8904 ± 0.0297	0.6505 ± 0.3142
MAE	0.3670 ± 0.0445	0.5835 ± 0.3229
PSNR [dB]	6.7289 ± 1.0629	4.4733 ± 6.0155

Jak możemy zaobserwować, lepsze wyniki w każdej z metryk uzyskał model VAEEG. Wynikać to może z faktu, iż był on przystosowany do rekonstrukcji pojedynczego kanału, gdy Diff-E rekonstruował równolegle wszystkie kanały na raz, uwzględniając informacje między nimi. Na Rysunku ?? przedstawione mamy dodatkowo przykładowe rekonstrukcje.

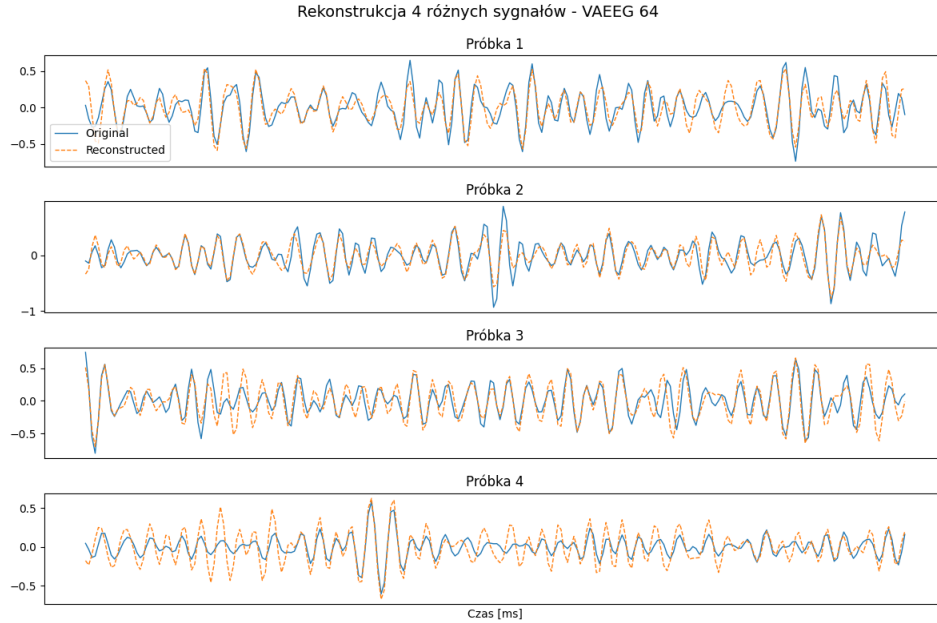


Figure 5: Rekonstrukcje modelu VAEEG 64

6 Wnioski i kierunki dalszych prac

Niniejsza praca stanowi punkt wyjścia do dalszych badań nad wykorzystaniem modeli generatywnych w przetwarzaniu sygnałów EEG. Przeprowadzone eksperymenty nie pozwalają dojść do konkluzji na temat przydatności zbadanych modeli. Mimo że model VAE osiąga lepszą jakość rekonstrukcji niż model dyfuzyjny, nie można dokonać bezpośredniego porównania między nimi, ze względu na przewagę VAE poprzez otrzymywanie na wejście niezaszumionych próbek. Pozostaje do zbadania możliwość zastosowania transfer learningu, gdzie wytrenowany enkoder służy jako ekstraktor cech w nowych zadaniach, takich jak wykrywanie napadów padaczkowych, klasyfikacja stanów poznawczych czy detekcja nieprawidłowości neurologicznych.




Figure 6: Rekonstrukcje modelu Diff-E 128

7 Podział prac

Każdy z członków zespołu skupił się na jednym z dwóch zbadanych modeli. Szymon Stano zajął się implementacją i eksperymentami z modelem VAEEG natomiast Marek Fiuk dostosowaniem i eksperymentami modelu Diff-E zgodnie z odpowiadającymi artykułami(2; 1). Obaj członkowie zespołu byli zaangażowani w preprocessing danych, Szymon Stano dokonał ewaluacji modeli.

Źródła

- [1] S. Kim, Y.-E. Lee, S.-H. Lee, and S.-W. Lee, “Diff-e: Diffusion-based learning for decoding imagined speech eeg,” 2023. [Online]. Available: <https://arxiv.org/abs/2307.14389>
- [2] T. Zhao, Y. Cui, T. Ji, J. Luo, W. Li, J. Jiang, Z. Gao, W. Hu, Y. Yan, Y. Jiang, and B. Hong, “Vaeeg: Variational auto-encoder for extracting eeg representation,” *NeuroImage*, vol. 304, p. 120946, 2024. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1053811924004439>
- [3] G. R. Müller-Putz, “Chapter 18 - electroencephalography,” in *Brain-Computer Interfaces*, ser. Handbook of Clinical Neurology, N. F. Ramsey and J. del R. Millán, Eds. Elsevier, 2020, vol. 168, pp. 249–262. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/B9780444639349000184>
- [4] S. Wong, A. Simmons, J. Rivera-Villicana, S. Barnett, S. Sivathamboo, P. Perucca, Z. Ge, P. Kwan, L. Kuhlmann, R. Vasa *et al.*, “Eeg datasets for seizure detection and prediction—a review,” *Epilepsia Open*, vol. 8, no. 2, pp. 252–267, 2023.
- [5] G. R. Müller-Putz, “Electroencephalography,” *Handbook of clinical neurology*, vol. 168, pp. 249–262, 2020.
- [6] D. Patrycja and K. Ewa, ““a polish electroencephalography, alzheimer’s risk-genes, lifestyle and neuroimaging (pearl-neuro) database”,” 2024.
- [7] R. T. Schirrmeister, J. T. Springenberg, L. D. J. Fiederer, M. Glasstetter, K. Eggenberger, M. Tangermann, F. Hutter, W. Burgard, and T. Ball, “Deep learning with convolutional neural networks for brain mapping and decoding of movement-related information from the human EEG,” *CoRR*, vol. abs/1703.05051, 2017. [Online]. Available: <http://arxiv.org/abs/1703.05051>
- [8] V. Lawhern, A. Solon, N. Waytowich, S. Gordon, C. Hung, and B. Lance, “Eegnet: a compact convolutional neural network for eeg-based brain-computer interfaces,” *Journal of Neural Engineering*, vol. 15, 07 2018.

- [9] K. G. Hartmann, R. T. Schirrmeister, and T. Ball, “Eeg-gan: Generative adversarial networks for electroencephalographic (eeg) brain signals,” 2018. [Online]. Available: <https://arxiv.org/abs/1806.01875>
- [10] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, R. Goj, M. Jas, T. Brooks, L. Parkkonen, and M. S. Hämäläinen, “MEG and EEG data analysis with MNE-Python,” *Frontiers in Neuroscience*, vol. 7, no. 267, pp. 1–13, 2013.
- [11] J. Ho, A. Jain, and P. Abbeel, “Denoising diffusion probabilistic models,” in *Advances in Neural Information Processing Systems*, H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan, and H. Lin, Eds., vol. 33. Curran Associates, Inc., 2020, pp. 6840–6851. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2020/file/4c5bcfec8584af0d967f1ab10179ca4b-Paper.pdf